

APÉNDICE METODOLÓGICO

Construcción de las bases de asignaciones presupuestarias de los departamentos de Tacna, Moquegua, Puno y Arequipa en el Proyecto de Ley de Presupuesto del Sector Público para el Año Fiscal 2027

Este apéndice documenta los procedimientos aplicados para extraer de los anexos del proyecto de ley todas las asignaciones presupuestarias correspondientes a los distritos y provincias de Tacna, Moquegua, Puno y Arequipa, y a las obras, actividades, proyectos y servicios públicos ejecutados en esas jurisdicciones. Está escrito para que un tercero reproduzca el resultado con los mismos insumos, o repita el procedimiento para otro departamento o para otro año fiscal.

Los productos son seis archivos: cuatro bases departamentales con el mismo esquema de 25 variables, un catálogo conjunto de 340 pliegos derivado de ellas, y un script de control que verifica la integridad de cualquiera de las bases. Ninguna cifra entra sin cuadrar contra un subtotal impreso en los propios anexos, y los pliegos que no cierran quedan marcados fila por fila con su diferencia exacta.

Producto	Filas	Monto de la base (\$/)	Pliegos que cierran
Base de Tacna	863	2 563 332 924	30 de 30
Base de Moquegua	703	1 981 093 292	23 de 23
Base de Puno	2 417	6 161 078 501	109 de 112
Base de Arequipa	1 992	7 705 031 301	108 de 111
Catálogo conjunto	340 pliegos	18 410 272 218	270 de 276

1. Insumos y entorno

Once archivos PDF con los anexos del proyecto remitido el 27 de agosto de 2026, que suman 2 578 páginas. Los departamentos aparecen en archivos distintos según el ordenamiento alfabético: Tacna no figura en los archivos 6-1 ni 7-1-2, mientras que Moquegua y Puno aparecen en ambas mitades del anexo 7.

Los PDF son escaneos con capa de texto generada por reconocimiento óptico. El entorno de trabajo fue Linux con Poppler para el tratamiento de los PDF, Python 3.12 para la extracción y Node.js para la redacción de los documentos. Ninguna dependencia es propietaria.

2. Preparación de los archivos

Primer paso: copiar los PDF a disco local. Leerlos desde el punto de montaje de origen provoca errores de entrada y salida en los archivos grandes, y el mayor pesa 184 MB. Después se verifica el número de páginas y la presencia de capa de texto; si el conteo de fuentes de la primera página fuera cero, el archivo sería una imagen y habría que aplicar reconocimiento óptico antes de continuar.

```
mkdir -p pdfs && cp /ruta/origen/*.pdf pdfs/
for f in pdfs/*.pdf; do
  pdftoinfo "$f" | awk '/^Pages/{print $2}'
  pdffonts -l 1 "$f" | tail -n +3 | wc -l    # >0 confirma capa de texto
  pdftotext -layout "$f" txt/${basename "$f"}.pdf).txt
done
```

La extracción no se hace sobre texto plano sino sobre las coordenadas de cada palabra. Es la decisión técnica que sostiene todo lo demás y conviene explicar por qué.

Con texto plano, el importe de una partida puede caer en la línea del código, en la anterior o en la siguiente, según cuánto ocupe la denominación. No hay regla que acierte siempre: probadas las dos vinculaciones posibles sobre un pliego de contraste, hacia atrás recuperaba 57 proyectos y hacia adelante 31, y ninguna llegaba al subtotal impreso. Con coordenadas la ambigüedad desaparece, porque en el documento real el importe y su etiqueta comparten banda vertical. Las palabras se agrupan en líneas por cercanía de su centro vertical, con tolerancia de 3,2 puntos.

La coordenada horizontal aporta además la jerarquía —la sangría distingue categoría, producto y actividad— y permite separar el nombre de las cifras por un umbral fijo, de modo que una letra intrusa del reconocimiento óptico dentro del nombre no se confunda con un importe.

3. Delimitación del universo

El universo se delimita por código de pliego, no por el nombre del departamento. Es la decisión metodológica que más afecta la completitud del resultado.

Una búsqueda de la cadena «Tacna» sobre los once archivos devuelve resultados incompletos. En el Anexo 8 hay páginas que asignan recursos a municipalidades del departamento sin que la palabra aparezca: la fila dice «230303 Municipalidad Distrital de Ite» y el nombre del departamento figura solo en el encabezado del programa presupuestal, varias páginas antes. Tres programas presupuestales completos se detectan únicamente por código. A eso se añade que el reconocimiento óptico deforma la palabra en algunas hojas, donde aparece «TACHA».

Código	Entidad
460	Gobierno Regional del Departamento de Tacna. Se verifica por el orden alfabético del anexo 6: 459 San Martín, 460 Tacna, 461 Tumbes
531	Universidad Nacional Jorge Basadre Grohmann, en el bloque de universidades del Gobierno Nacional
230101 a 230111	Once municipalidades de la provincia de Tacna
230201 a 230206	Seis municipalidades de la provincia de Candarave
230301 a 230303	Tres municipalidades de la provincia de Jorge Basadre
230401 a 230408	Ocho municipalidades de la provincia de Tarata

En los códigos municipales de seis dígitos, los dos primeros son el departamento, los dos siguientes la provincia y los dos últimos el distrito. Una expresión regular sobre el patrón 230[1-4] recupera los veintiocho pliegos locales en una sola pasada. Los pliegos nacionales entran por un criterio distinto, descrito en la sección 6.4.

4. Criterio de exclusión de agregados

La base contiene solo asignaciones elementales. Ningún subtotal ni total del proyecto de ley entra en ella. La exclusión no se hace por palabras clave sino por posición en el árbol de cada anexo: se conservan las hojas y se descartan los nodos que suman a sus hijos.

4.1 Anexos 5 y 6

Jerarquía: categoría presupuestaria, luego los encabezados de productos, proyectos y actividades, luego el producto con código de siete dígitos iniciado en 3, y debajo sus actividades iniciadas en 5. Los proyectos, iniciados en 2, cuelgan directamente del encabezado de proyectos y no tienen hijos.

Son hojas las actividades y los proyectos. Los productos se descartan porque suman sus actividades, con una excepción verificada caso por caso: dos productos del pliego 460 no tienen ninguna actividad debajo y por tanto son la asignación misma. Descartarlos habría dejado un faltante de 3 150 526 soles frente al total del pliego, y fue así como se detectaron.

4.2 Anexo 7

Jerarquía: departamento, provincia, pliego, genérica agregada y subgenérica. Las tres líneas de gastos corrientes, gastos de capital y servicio de la deuda son agregados de sus subgenéricas y se descartan, igual que las filas de pliego, provincia y departamento.

La hoja es la subgenérica cruzada con la fuente de financiamiento, porque el anexo abre cada línea por fuente y ese cruce es el nivel más desagregado disponible. Una misma subgenérica genera por tanto tantas filas como fuentes la financien.

4.3 Anexo 8 y Anexo A

En el Anexo 8 la jerarquía es programa presupuestal, nivel de gobierno y pliego. La hoja es la asignación que cada pliego recibe dentro de un programa. El Anexo A aporta una sola línea, una subvención a persona jurídica.

4.4 Anexos excluidos por completo

El Anexo 4 queda fuera porque presenta únicamente agregados de pliego por fuente de financiamiento, sin partidas; se usa como fuente de contraste, no como origen de filas. El Anexo C también queda fuera porque registra ingresos, que no son asignaciones de gasto. El Anexo B no tiene registros del departamento.

5. Extracción

5.1 Nombres partidos en varias líneas

La denominación de una partida se corta cuando excede el ancho de la columna. La rutina captura la primera línea con una expresión regular de tres grupos —código, denominación, monto— y concatena las siguientes mientras no empiecen con un código de partida, con un encabezado de sección o con una cifra alineada a la derecha, y sin pasar de tres líneas. Ese corte triple evita que se peguen dos partidas distintas. Sin la concatenación se pierde información sustantiva: varias partidas nacionales nombran a Tacna solo en la línea de continuación.

5.2 El arrastre del encabezado de página

Cada hoja repite en su encabezado la línea del pliego, la de la categoría presupuestaria y la de la subsección. Tratar cualquiera de esas repeticiones como un cambio real reinicia el contexto y deja huérfanas a las

actividades que abren página, con lo que sus productos parecen no tener hijos y se emiten como si fueran la asignación misma. Es la misma patología en tres niveles y produce doble cómputo.

La corrección es reiniciar el contexto solo cuando el valor cambia de verdad. El efecto de no hacerlo se midió: el anexo 6 pasaba de sobrecontar doce mil millones a quedar dentro del margen esperado. Conviene señalarlo porque la línea aparece indistintamente como «Pliego :» y como «Pliego:», y el desajuste no es visible sin un control de cierre.

En la misma línea, el emparejamiento entre un producto y sus actividades debe hacerse por código y no por denominación: el reconocimiento óptico lee el mismo nombre de forma distinta en dos páginas y el vínculo se rompe.

5.3 Las columnas de fuente del Anexo 7

El Anexo 7 abre cada línea en cinco columnas de fuente más el total, y muchas celdas están vacías, de modo que contar las cifras de izquierda a derecha da resultados falsos. Tampoco sirve anclar en las palabras del encabezado: no están alineadas con las cifras y en algunas hojas el reconocimiento óptico las deja ilegibles.

El procedimiento definitivo se apoya en cuatro reglas:

- El anclaje se calcula una sola vez para todo el anexo, no página por página. Las columnas ocupan la misma posición en todas las hojas, así que la posición de cada una se vota sobre los centenares de líneas de pliego, comparando sus cifras con los valores por fuente que el Anexo 4 declara para ese mismo pliego. Es un anclaje sobre los datos, no sobre la maquetación.
- En cada línea, la última cifra es siempre el total. Se separa antes de asignar columnas y sirve como verificación, no como dato.
- Si a una línea le falta una cifra y el pliego tiene una sola fuente sin cubrir, la diferencia contra el total de la línea la determina.
- La identificación del pliego usa el último nombre inequívoco visto para fijar el bloque departamental en curso. Hay distritos homónimos en varios departamentos —San Cristóbal, San Antonio— y sin ese contexto sus líneas se atribuyen al primero en orden alfabético, con lo que dos pliegos desaparecen y otros dos se inflan.
- Los homónimos también se repiten dentro de un mismo departamento: Puno tiene tres municipalidades distritales de Santa Rosa. Un índice por nombre conserva solo la última y descuadra a las demás, así que las homónimas se guardan en orden de código y se consumen secuencialmente, que es el orden en que el anexo las lista.
- El código del departamento se aprende del encabezado, que está impreso a una sangría menor que el de la provincia, y se cachea. Deducirlo de las coincidencias no basta: si un bloque departamental abre con varios homónimos, el contexto anterior los arrastra al departamento equivocado. Así se resolvió Coporaque, que había absorbido 16,9 millones de soles de su homónimo del Cusco.
- Los nombres largos aparecen truncados, porque el anexo los corta. Una coincidencia por prefijo los recupera, mientras que la comparación aproximada no llega al umbral: «Municipalidad Distrital de Coronel Gregorio» y el nombre completo con «Albarracín Lanchipa» quedan en 0,81 de similitud.
- Una reconciliación final compara, pliego por pliego, la suma de cada fuente contra la que declara el anexo 4. Cuando una fuente excede lo declarado y existe un único componente de esa fuente cuyo valor es exactamente el exceso, ese componente es espurio y se retira. Aparece cuando el reconocimiento óptico daña el total de una línea y la diferencia se materializa como una celda fantasma.

Sobre el conjunto del país, el extractor identifica 1 880 de los 1 887 pliegos locales y cierra 1 836, el 97 %. En Tacna y Moquegua cierran todos; en Puno, 107 de 110, y en Arequipa, 103 de 107.

5.4 Localización de las partidas nacionales

Un ministerio ejecuta en todo el país, así que su presupuesto no es una asignación a Tacna. Solo entran a la base las partidas cuya obra o servicio se ubica en el departamento. La denominación de los proyectos termina con un bloque de ubicación del tipo «distrito de X, provincia Y, departamento Z», que es lo que se examina.

La condición de entrada es el nombre del departamento, no los de sus distritos. En Moquegua bastaban los nombres de distrito porque son distintivos, pero Puno tiene San Antonio, Santa Rosa, San Juan y Cabana, que aparecen en partidas de medio país: usarlos como filtro arrastraba a la base el presupuesto nacional entero.

La variable de alcance territorial toma tres valores. «Localizada en Tacna» cuando el bloque final nombra una jurisdicción del departamento o el nombre cita la región. «Multidepartamental, incluye Tacna» cuando la partida abarca varios departamentos y Tacna es uno de ellos; son tres partidas por 40 750 910 soles, de las cuales solo una fracción indeterminada corresponde al departamento. El tercer caso son las partidas que nombran a Tacna pero se ejecutan en otra jurisdicción, que quedan fuera de la base: son cinco y se identifican por su propio bloque de ubicación.

Partida	Ubicación real	Monto (S/)
2509941, M. de Educación	I.E. 7047 Tacna – Barranco, distrito de Barranco, Lima	47 110
2637109, M. de Comercio Exterior	Boulevard Tacna – Pucallpa, distrito de Callería, Ucayali	2 757
2548857, SUNARP	Oficina Registral Moquegua, Zona Registral N.º XIII con sede en Tacna	134 916
2548859, SUNARP	Oficina Registral Ilo, Zona Registral N.º XIII con sede en Tacna	134 916
2548869, SUNARP	Oficina Registral Juliaca, Zona Registral N.º XIII con sede en Tacna	202 375

El caso de SUNARP muestra por qué el criterio no puede ser la mención: las tres oficinas dependen administrativamente de la zona registral con sede en Tacna, pero el equipamiento se instala en Moquegua, Ilo y Juliaca.

5.5 Jurisdicciones mencionadas

Cada asignación registra las jurisdicciones de Tacna que su denominación nombra, cotejando el texto contra los veintiocho distritos y las cuatro provincias, con las variantes que introduce el reconocimiento óptico. Para los pliegos locales la jurisdicción es la propia. La variable permite responder qué recibe cada distrito sin depender de que la obra esté en su pliego: 509 de las 854 asignaciones nombran al menos una jurisdicción.

6. Catálogo por pliego y script de control

6.1 Catálogo

El catálogo se deriva agrupando las cuatro bases por código de pliego, con el departamento como variable. Ninguna entidad se agrega a mano, de modo que no puede desincronizarse de lo que describe. Resultan 340 pliegos, de los cuales 274 tienen sede en alguno de los cuatro departamentos y los demás son ministerios y organismos con obras localizadas en ellos.

Es una tabla de resumen, con once variables: la identificación del pliego, los anexos y páginas donde aparece, el número de asignaciones, el monto y la regla con que se calculó.

- El monto suma solo las filas de la base no duplicada.
- La columna que declara qué mide el monto es indispensable, porque la regla cambia: para los pliegos con sede en el departamento es el presupuesto institucional completo; para los ministerios es solo la porción localizada allí. Las dos cifras no son comparables y sumar la columna entera mezcla ambas magnitudes.
- Los códigos conservan sus ceros a la izquierda —tres dígitos en gobierno nacional y regional, seis en local— porque son la llave de unión con las bases. Una hoja de cálculo que los interprete como números la rompe.

6.2 Script de control

Los anexos no son partes de una tabla sino cortes distintos del mismo dinero, así que la ausencia de duplicación no puede darse por supuesta: hay que verificarla. El script hace cuatro comprobaciones y devuelve código de salida distinto de cero si alguna falla, para encadenarlo en un proceso automático.

```
python3 control-asignaciones.py base.csv [--ref ref4.json]
```

- Partición por nivel de gobierno. Los anexos 5, 6 y 7 cubren conjuntos de pliegos disjuntos porque cada uno corresponde a un nivel distinto. Una intersección delata un error de lectura.
- Contención de los cortes transversales. El Anexo 8 reorganiza por programa presupuestal dinero ya consignado en los anexos 6 y 7, de modo que en ningún pliego puede exceder su base. Esta comprobación detectó por sí sola que un pliego de Moquegua estaba incompleto, antes de que lo hiciera el cierre.
- Ausencia de filas idénticas repetidas dentro de un mismo anexo.
- Cierre por pliego contra el total impreso, salvo en los pliegos nacionales, que aportan solo su porción territorial y quedan marcados como no aplicables.

Sobre las bases de Tacna y Moquegua el control corre sin observaciones. En las de Puno y Arequipa señala los siete pliegos que no cierran, que es exactamente lo que debe hacer.

El control se publica junto con los datos. Un conjunto de datos sin el instrumento para verificarlo obliga a confiar en quien lo produjo; con él, cualquiera puede reproducir la comprobación en un minuto.

6.3 La referencia del anexo 4

Todos los controles se apoyan en una referencia construida desde el anexo 4, que es el único que imprime, en una sola tabla, el código de cada pliego, su denominación, su desagregación por fuente y su total. De ahí salen las 2 077 entradas contra las que se valida cada pliego y el conjunto de fuentes activas que restringe la lectura del anexo 7.

Esa referencia tiene su propio control: el anexo 4 imprime los totales por nivel de gobierno, y la suma de las entradas extraídas debe reproducirlos. Al aplicarlo aparecieron tres defectos que conviene documentar porque son fáciles de repetir.

- El código de pliego se repite entre sectores, de modo que deduplicar por código al sumar los niveles pierde entidades enteras. La unidad es el par de código y nombre.
- El reconocimiento óptico leyó 484 donde el anexo dice 464, con lo que el Gobierno Regional de la Provincia Constitucional del Callao quedaba contado como pliego nacional. Su monto era exactamente la brecha del nivel regional.
- Veinticinco pliegos faltaban por deformación del nombre —Cocachamba como «Cocae1amba», Quechualla como «Quechual1a»— entre ellos la Presidencia del Consejo de Ministros y el Poder Judicial. Tres eran municipalidades que aparecían en el anexo 8 sin contraparte en el 7, y ese síntoma fue el que las delató.

Con esas correcciones el nivel regional cierra exacto contra los 58 671 738 588 impresos, el nacional queda a 1,3 % y el local a 0,78 %.

6.4 Contraste entre anexos

El anexo 5 da el total de cada pliego nacional por otra vía: la suma de sus hojas. Compararlo con el anexo 4 permite localizar qué pliegos están mal leídos, y en cuál de los dos.

El emparejamiento debe hacerse por código y no por nombre. Con el nombre solo coinciden 132 de los 159 pliegos, porque el reconocimiento óptico deforma denominaciones como «M. BEL INTERIOR». Con el código emparejan los 158 que tienen bloque en ambos anexos, y el nombre queda para desempatar los códigos que se repiten entre sectores, que es el único lugar donde hace falta. De esos 158, coinciden exactamente 147 y la diferencia total baja a 22 millones de soles.

El contraste no es un ejercicio de verificación: sirvió para corregir datos entregados. Reveló que faltaban 858 millones de soles del Ministerio de Transportes y 369 del Instituto Peruano del Deporte, ambos por defectos de lectura del importe descritos en la sección 5, y como el transporte concentra las mayores inversiones nacionales en cada región, esas partidas faltaban también en las bases departamentales.

7. Controles de validación

Cada bloque se valida contra un subtotal impreso en el propio anexo. Estos son los controles aplicados y sus resultados:

Control	Resultado (S/)	Estado
Hojas del pliego 460 contra su total impreso, Tacna	986 582 046	Cuadra
Hojas del pliego 455 contra su total impreso, Moquegua	768 940 447	Cuadra
Universidad Jorge Basadre Grohmann, pliego 531	176 845 803	Cuadra
Universidad Nacional de Moquegua, pliego 545	64 616 600	Cuadra
Anexo 7, los 28 pliegos locales de Tacna	1 186 851 544	28 de 28
Anexo 7, los 21 pliegos locales de Moquegua	1 015 567 508	21 de 21
Universidades del Altiplano y de Juliaca, pliegos 520 y 552	286 166 858 y 49 055 887	Cuadra
Universidad Nacional de San Agustín, pliego 513	452 435 006	Cuadra
Anexo 6, gobierno regional de Arequipa	3 096 683 402	Cuadra
Anexo 7, los 110 pliegos locales de Puno	1 635 357 489	107 de 110
Anexo 7, los 107 pliegos locales de Arequipa	2 529 059 189	103 de 107
Anexo 6, gobierno regional de Puno	3 406 560 538	Corto en 7 789 915
Anexo 8 contra la base que replica, ambas regiones	692 002 101 y 498 984 962	Sin excesos
Catálogo por pliego contra las cuatro bases	18 410 272 218	Cuadra

Control	Resultado (S/)	Estado
Referencia del anexo 4 contra el total regional impreso	58 671 738 588	Cuadra
Anexo 5 contra el anexo 4, pliego por pliego	147 de 158	Difieren 22 305 540

Los controles no son un trámite final: son el instrumento que permite corregir sin conjeturas. La reparación opera en tres niveles y siempre por diferencia contra una cifra impresa, nunca por estimación. Si a un producto le falta el importe de una sola actividad, se recupera restando las hermanas de su total. Si falta el de un solo proyecto, se recupera contra el subtotal de su subsección. Y si a un pliego le falta o le sobra un importe y existe una única línea cuyos componentes no reconcilian con su propio total, la diferencia se imputa ahí. Cuando hay más de una candidata la rutina no actúa: reparte a ciegas sería peor que dejar la marca.

El límite del método aparece cuando falta más de una cifra en el mismo grupo. En el gobierno regional de Puno hay tres proyectos de la misma subsección con el importe ilegible, que juntos suman 7 789 915 soles: tres incógnitas y una sola ecuación. Esas partidas quedan en la base con el monto vacío y su nota, y el pliego se marca como no cerrado. Repartir la diferencia habría sido inventar.

El criterio de qué referencia manda también está resuelto. El total del Anexo 4 se acepta solo si sus propias fuentes lo suman; cuando el reconocimiento óptico dañó un dígito del total, la suma de fuentes prevalece. Así se resolvió el caso de la Municipalidad Provincial de Tarata, impresa como 7 918 284 en un anexo y 7 918 264 en otro.

8. Incidencias de reconocimiento óptico

Toda corrección se resuelve por diferencia contra una cifra impresa, nunca por estimación, y queda registrada con su lectura original para que pueda verificarse contra el PDF.

Pliego	Genérica	Incidencia	Lectura del OCR	Valor adoptado
230108 Pocollay	2.5 Otros gastos	Total impreso ilegible	29 460	129 460
230203 Camilaca	2.1 Personal	Total impreso ilegible	268 300	268 360
230203 Camilaca	2.1 Personal	Componente corregido por cierre de pliego y de fuente	244 660	244 600
230301 Locumba	2.6 Activos no financieros	Total impreso ilegible	84 189 984	84 169 984
230303 Ite	2.3 Bienes y servicios	Celda partida por el OCR	101 535	10 067 168

El caso de Ite es ilustrativo. La celda de recursos determinados se imprimió como «101367 168», que el lector interpreta como dos números. El valor correcto, 10 067 168, se obtiene restando al total de la línea el componente de recursos directamente recaudados, y coincide con la diferencia entre el agregado de gasto corriente y las demás subgenéricas.

Se corrigieron además tres denominaciones deformadas: Calana, Palca y La Yarada Los Palos aparecían como «Galana», «Paica» y «La Varada». La corrección se aplicó en la base y no solo en la presentación, porque el nombre del pliego es la clave de unión con el catálogo.

9. Diccionario de variables

9.1 Base de asignaciones

863 filas para Tacna, 703 para Moquegua, 2 417 para Puno y 1 990 para Arequipa. Las tres comparten las mismas 25 variables en el mismo orden, en UTF-8 con marca de orden de bytes y separador de punto y coma, de modo que pueden concatenarse directamente.

Variable	Contenido	Valores o formato
anexo	Anexo del proyecto de ley	5, 6, 7, 8, A
archivo_pdf	Archivo de origen	Nombre del PDF
pagina_pdf / paginaimpresa	Página en el PDF y numeración correlativa del proyecto	Entero
nivel_gobierno	Nivel de gobierno del pliego	Nacional, regional o local
codigo_pliego / pliego	Entidad titular del presupuesto	Tres dígitos, o seis en locales
provincia / distrito	Jurisdicción del pliego local	Vacío en nacionales y regional
nota	Incidencia de lectura y su tratamiento	Texto; vacío en la mayoría
cuadra_el_pliego / diferencia_del_pliego	Si el pliego cierra y en cuánto difiere	Sí, No, No aplica; entero con signo
jurisdicciones_mencionadas	Distritos y provincias que nombra la denominación	Separados por barra vertical
categoria_presupuestal	Categoría a la que pertenece la partida	Programas presupuestales, acciones centrales, APNOP
programa_presupuestal	Programa, en las filas del anexo 8	Denominación; el anexo no asigna código
producto	Producto padre, en las actividades	Código y denominación
codigo_partida	Código de la partida	Siete dígitos iniciados en 2, 3 o 5; genérica del gasto; vacío
tipo_partida	Naturaleza de la asignación	Actividad, proyecto de inversión, producto sin actividades, genérica del gasto, asignación por programa presupuestal, subvención
concepto	Denominación de la partida	Texto
fuelle_financiamiento	Fuente, donde el anexo la desagrega	Cinco valores; solo en el anexo 7
monto_soles	Monto asignado	Entero sin separadores
alcance_territorial	Dónde se ejecuta la obra o el servicio	Localizada en Tacna; multidepartamental, incluye Tacna
base_no_duplicada	Si la fila puede sumarse con las demás	Sí; No, replica los anexos 6 y 7

9.2 Catálogo por pliego

340 filas y 11 columnas, las cuatro regiones en una sola tabla. La clave es el par de departamento y código de pliego.

Variable	Contenido	Valores o formato
departamento	Región a la que corresponde la fila	Tacna o Moquegua

Variable	Contenido	Valores o formato
codigo_pliego / pliego	Clave de unión y denominación	Texto
sectores_principales	Los tres sectores de mayor monto del pliego	Texto con montos
nivel_gobierno / provincia / distrito	Ubicación institucional	Texto
anexos	Anexos donde aparece el pliego	Lista separada por comas
n_asignaciones / monto_asignado_soles	Filas y monto de la base no duplicada	Entero
n_proyectos_inversion / monto_...	Proyectos de inversión del pliego	Vacío si no tiene
n_actividades / monto_...	Actividades del pliego	Vacío si no tiene
n_genericas_gasto / monto_...	Genéricas del gasto del pliego	Solo gobiernos locales
monto_programas_presupuestales	Monto en esa categoría	Vacío si no aplica
monto_acciones_centrales / monto_apnop	Monto en esas categorías	Vacío si no aplica
recursos_ordinarios y las tres siguientes	Desagregación por fuente	Solo gobiernos locales
pct_recursos_determinados	Peso de los recursos determinados	Decimal con coma
n_asignaciones_anexo8 / monto_anexo8	El cruce por programa presupuestal, en columnas aparte	Entero
partidas_multidepartamentales	Partidas de alcance más amplio que el departamento	Entero o vacío
referencia_paginas_pdf	Páginas por archivo, con rangos comprimidos	Texto

10. Advertencias de uso

- Las 170 filas del Anexo 8 replican por programa presupuestal recursos ya consignados en los anexos 6 y 7. Filtrar por la variable de base no duplicada antes de sumar.
- Las tres partidas multidepartamentales abarcan varios departamentos y solo una fracción indeterminada corresponde a Tacna. La mayor son los 18 000 000 del Instituto Nacional de Innovación Agraria en 33 distritos de diez departamentos.
- Los recursos determinados no son sinónimo de canon. La fuente agrupa canon y sobrecanon, regalías, renta de aduanas y participaciones, contribuciones a fondos, impuestos municipales y Fondo de Compensación Municipal. El desglose por rubro no está en los anexos.
- Las asignaciones de diez mil soles o menos son en su mayoría partidas simbólicas de continuidad, que habilitan la línea sin financiar ejecución significativa.
- Se trata de un proyecto de ley. Las cifras cambian con el debate parlamentario y con la autógrafa; las bases reflejan el texto remitido el 27 de agosto de 2026.
- El sector es una clasificación funcional derivada de la denominación de la partida, de su producto padre y del programa presupuestal, con reglas ordenadas donde la primera coincidencia decide. Las líneas del Anexo 7 no admiten sector, porque el anexo abre por genérica del gasto y no por función: llevan el valor «No sectorizable», que es una constatación del anexo y no una falla de la clasificación.
- Cualquier cifra que vaya a citarse textualmente en un documento oficial debe verificarse contra el PDF original en la página indicada, por la naturaleza del reconocimiento óptico.

11. Secuencia de replicación

1. Copiar los PDF a disco local; verificar páginas y capa de texto.
2. Extraer el texto conservando la disposición espacial y separar por páginas.
3. Identificar los códigos de pliego del departamento de interés. Para otro departamento cambian los dos primeros dígitos del código municipal y el código del gobierno regional, que se verifica por el orden alfabético del anexo 6.
4. Recorrer los once archivos buscando esos códigos, nunca el nombre del departamento.
5. Reconstruir el árbol de cada anexo y conservar solo las hojas, comprobando si algún nodo intermedio carece de hijos.
6. Concatenar los nombres partidos en varias líneas antes de aplicar cualquier filtro de texto.
7. Leer el anexo 7 por posición de columna, con el último número de cada línea como total y las fuentes candidatas restringidas por el anexo 4.
8. Clasificar las partidas nacionales por su bloque de ubicación y descartar las que se ejecutan fuera del departamento.
9. Ejecutar los ocho controles de la sección 7. Si alguno no cuadra, localizar la línea y resolver por diferencia contra una cifra impresa, documentando la corrección.
10. Derivar el catálogo agrupando la base por código de pliego y comprobar que cierre contra ella.

El paso decisivo es el de los controles. Los controles no son un trámite final: cada descuadre detectado en este trabajo señaló un defecto real de lectura —el arrastre del encabezado, la alineación de columnas, cinco celdas dañadas— y ninguno se resolvió ajustando la cifra al resultado esperado.