

APÉNDICE METODOLÓGICO

Construcción de las bases de asignaciones presupuestarias de los departamentos de Tacna y Moquegua en el Proyecto de Ley de Presupuesto del Sector Público para el Año Fiscal 2027

Este apéndice documenta los procedimientos aplicados para extraer de los anexos del proyecto de ley todas las asignaciones presupuestarias correspondientes a los distritos y provincias de Tacna y de Moquegua, y a las obras, actividades, proyectos y servicios públicos ejecutados en esas jurisdicciones. Está escrito para que un tercero reproduzca el resultado con los mismos insumos, o repita el procedimiento para otro departamento o para otro año fiscal.

Los productos son cuatro archivos: una base de 854 asignaciones para Tacna, una de 709 para Moquegua, un catálogo conjunto de 78 pliegos derivado de ambas, y un script de control que verifica la integridad de cualquiera de las bases. Ninguna cifra entra sin cuadrar contra un subtotal impreso en los propios anexos: los 53 pliegos con sede en los dos departamentos cierran al sol.

Producto	Filas	Monto de la base (\$/)	Pliegos que cierran
Base de Tacna	854	2 562 810 850	30 de 30
Base de Moquegua	709	2 027 679 753	23 de 23
Catálogo conjunto	78 pliegos	—	53 de 53

1. Insumos y entorno

Once archivos PDF con los anexos del proyecto remitido el 27 de agosto de 2026, que suman 2 578 páginas. Los dos departamentos aparecen en anexos distintos según el nivel de gobierno: Tacna no figura en los archivos 6-1 ni 7-1-2 porque el ordenamiento alfabético la sitúa en las segundas partes, mientras que Moquegua sí aparece en ambas mitades del anexo 7.

Los PDF son escaneos con capa de texto generada por reconocimiento óptico. El entorno de trabajo fue Linux con Poppler para el tratamiento de los PDF, Python 3.12 para la extracción y Node.js para la redacción de los documentos. Ninguna dependencia es propietaria.

2. Preparación de los archivos

Primer paso: copiar los PDF a disco local. Leerlos desde el punto de montaje de origen provoca errores de entrada y salida en los archivos grandes, y el mayor pesa 184 MB. Después se verifica el número de páginas y la presencia de capa de texto; si el conteo de fuentes de la primera página fuera cero, el archivo sería una imagen y habría que aplicar reconocimiento óptico antes de continuar.

```
mkdir -p pdfs && cp /ruta/origen/*.pdf pdfs/
for f in pdfs/*.pdf; do
  pdffonts "$f" | awk '/^Pages/{print $2}'
  pdffonts -l 1 "$f" | tail -n +3 | wc -l # >0 confirma capa de texto
  pdftotext -layout "$f" txt/${basename "$f"}.pdf.txt
done
```

La extracción no se hace sobre texto plano sino sobre las coordenadas de cada palabra. Es la decisión técnica que sostiene todo lo demás y conviene explicar por qué.

```
pdftotext -bbox-layout entrada.pdf salida.xml
```

Con texto plano, el importe de una partida puede caer en la línea del código, en la anterior o en la siguiente, según cuánto ocupe la denominación. No hay regla que acierte siempre: probadas las dos vinculaciones

posibles sobre un pliego de contraste, hacia atrás recuperaba 57 proyectos y hacia adelante 31, y ninguna llegaba al subtotal impreso. Con coordenadas la ambigüedad desaparece, porque en el documento real el importe y su etiqueta comparten banda vertical. Las palabras se agrupan en líneas por cercanía de su centro vertical, con tolerancia de 3,2 puntos.

La coordenada horizontal aporta además la jerarquía —la sangría distingue categoría, producto y actividad— y permite separar el nombre de las cifras por un umbral fijo, de modo que una letra intrusa del reconocimiento óptico dentro del nombre no se confunda con un importe.

3. Delimitación del universo

El universo se delimita por código de pliego, no por el nombre del departamento. Es la decisión metodológica que más afecta la completitud del resultado.

Una búsqueda de la cadena «Tacna» sobre los once archivos devuelve resultados incompletos. En el Anexo 8 hay páginas que asignan recursos a municipalidades del departamento sin que la palabra aparezca: la fila dice «230303 Municipalidad Distrital de Ite» y el nombre del departamento figura solo en el encabezado del programa presupuestal, varias páginas antes. Tres programas presupuestales completos se detectan únicamente por código. A eso se añade que el reconocimiento óptico deforma la palabra en algunas hojas, donde aparece «TACHA».

Código	Entidad
460	Gobierno Regional del Departamento de Tacna. Se verifica por el orden alfabético del anexo 6: 459 San Martín, 460 Tacna, 461 Tumbes
531	Universidad Nacional Jorge Basadre Grohmann, en el bloque de universidades del Gobierno Nacional
230101 a 230111	Once municipalidades de la provincia de Tacna
230201 a 230206	Seis municipalidades de la provincia de Candarave
230301 a 230303	Tres municipalidades de la provincia de Jorge Basadre
230401 a 230408	Ocho municipalidades de la provincia de Tarata

En los códigos municipales de seis dígitos, los dos primeros son el departamento, los dos siguientes la provincia y los dos últimos el distrito. Una expresión regular sobre el patrón 230[1-4] recupera los veintiocho pliegos locales en una sola pasada. Los pliegos nacionales entran por un criterio distinto, descrito en la sección 6.4.

4. Criterio de exclusión de agregados

La base contiene solo asignaciones elementales. Ningún subtotal ni total del proyecto de ley entra en ella. La exclusión no se hace por palabras clave sino por posición en el árbol de cada anexo: se conservan las hojas y se descartan los nodos que suman a sus hijos.

4.1 Anexos 5 y 6

Jerarquía: categoría presupuestaria, luego los encabezados de productos, proyectos y actividades, luego el producto con código de siete dígitos iniciado en 3, y debajo sus actividades iniciadas en 5. Los proyectos, iniciados en 2, cuelgan directamente del encabezado de proyectos y no tienen hijos.

Son hojas las actividades y los proyectos. Los productos se descartan porque suman sus actividades, con una excepción verificada caso por caso: dos productos del pliego 460 no tienen ninguna actividad debajo y por tanto son la asignación misma. Descartarlos habría dejado un faltante de 3 150 526 soles frente al total del pliego, y fue así como se detectaron.

4.2 Anexo 7

Jerarquía: departamento, provincia, pliego, genérica agregada y subgenérica. Las tres líneas de gastos corrientes, gastos de capital y servicio de la deuda son agregados de sus subgenéricas y se descartan, igual que las filas de pliego, provincia y departamento.

La hoja es la subgenérica cruzada con la fuente de financiamiento, porque el anexo abre cada línea por fuente y ese cruce es el nivel más desagregado disponible. Una misma subgenérica genera por tanto tantas filas como fuentes la financien.

4.3 Anexo 8 y Anexo A

En el Anexo 8 la jerarquía es programa presupuestal, nivel de gobierno y pliego. La hoja es la asignación que cada pliego recibe dentro de un programa. El Anexo A aporta una sola línea, una subvención a persona jurídica.

4.4 Anexos excluidos por completo

El Anexo 4 queda fuera porque presenta únicamente agregados de pliego por fuente de financiamiento, sin partidas; se usa como fuente de contraste, no como origen de filas. El Anexo C también queda fuera porque registra ingresos, que no son asignaciones de gasto. El Anexo B no tiene registros del departamento.

5. Extracción

5.1 Nombres partidos en varias líneas

La denominación de una partida se corta cuando excede el ancho de la columna. La rutina captura la primera línea con una expresión regular de tres grupos —código, denominación, monto— y concatena las siguientes mientras no empiecen con un código de partida, con un encabezado de sección o con una cifra alineada a la derecha, y sin pasar de tres líneas. Ese corte triple evita que se peguen dos partidas distintas. Sin la concatenación se pierde información sustantiva: varias partidas nacionales nombran a Tacna solo en la línea de continuación.

5.2 El arrastre del encabezado de página

Cada hoja repite en su encabezado la línea del pliego, la de la categoría presupuestaria y la de la subsección. Tratar cualquiera de esas repeticiones como un cambio real reinicia el contexto y deja huérfanas a las

actividades que abren página, con lo que sus productos parecen no tener hijos y se emiten como si fueran la asignación misma. Es la misma patología en tres niveles y produce doble cómputo.

La corrección es reiniciar el contexto solo cuando el valor cambia de verdad. El efecto de no hacerlo se midió: el anexo 6 pasaba de sobrecontar doce mil millones a quedar dentro del margen esperado. Conviene señalarlo porque la línea aparece indistintamente como «Pliego :» y como «Pliego:», y el desajuste no es visible sin un control de cierre.

En la misma línea, el emparejamiento entre un producto y sus actividades debe hacerse por código y no por denominación: el reconocimiento óptico lee el mismo nombre de forma distinta en dos páginas y el vínculo se rompe.

5.3 Las columnas de fuente del Anexo 7

El Anexo 7 abre cada línea en cinco columnas de fuente más el total, y muchas celdas están vacías, de modo que contar las cifras de izquierda a derecha da resultados falsos. Tampoco sirve anclar en las palabras del encabezado: no están alineadas con las cifras y en algunas hojas el reconocimiento óptico las deja ilegibles.

El procedimiento definitivo se apoya en cuatro reglas:

- El anclaje se calcula una sola vez para todo el anexo, no página por página. Las columnas ocupan la misma posición en todas las hojas, así que la posición de cada una se vota sobre los centenares de líneas de pliego, comparando sus cifras con los valores por fuente que el Anexo 4 declara para ese mismo pliego. Es un anclaje sobre los datos, no sobre la maquetación.
- En cada línea, la última cifra es siempre el total. Se separa antes de asignar columnas y sirve como verificación, no como dato.
- Si a una línea le falta una cifra y el pliego tiene una sola fuente sin cubrir, la diferencia contra el total de la línea la determina.
- La identificación del pliego usa el último nombre inequívoco visto para fijar el bloque departamental en curso. Hay distritos homónimos en varios departamentos —San Cristóbal, San Antonio— y sin ese contexto sus líneas se atribuyen al primero en orden alfabético, con lo que dos pliegos desaparecen y otros dos se inflan.

Sobre el conjunto del país, el extractor identifica 1 844 de los 1 887 pliegos locales y cierra 1 729, el 94 %. En Tacna y Moquegua cierran todos.

5.4 Localización de las partidas nacionales

Un ministerio ejecuta en todo el país, así que su presupuesto no es una asignación a Tacna. Solo entran a la base las partidas cuya obra o servicio se ubica en el departamento. La denominación de los proyectos termina con un bloque de ubicación del tipo «distrito de X, provincia Y, departamento Z», que es lo que se examina.

La variable de alcance territorial toma tres valores. «Localizada en Tacna» cuando el bloque final nombra una jurisdicción del departamento o el nombre cita la región. «Multidepartamental, incluye Tacna» cuando la partida abarca varios departamentos y Tacna es uno de ellos; son tres partidas por 40 750 910 soles, de las cuales solo una fracción indeterminada corresponde al departamento. El tercer caso son las partidas que nombran a Tacna pero se ejecutan en otra jurisdicción, que quedan fuera de la base: son cinco y se identifican por su propio bloque de ubicación.

Partida	Ubicación real	Monto (S/)
2509941, M. de Educación	I.E. 7047 Tacna – Barranco, distrito de Barranco, Lima	47 110
2637109, M. de Comercio Exterior	Boulevard Tacna – Pucallpa, distrito de Callería, Ucayali	2 757

Partida	Ubicación real	Monto (S/)
2548857, SUNARP	Oficina Registral Moquegua, Zona Registral N.º XIII con sede en Tacna	134 916
2548859, SUNARP	Oficina Registral Ilo, Zona Registral N.º XIII con sede en Tacna	134 916
2548869, SUNARP	Oficina Registral Juliaca, Zona Registral N.º XIII con sede en Tacna	202 375

El caso de SUNARP muestra por qué el criterio no puede ser la mención: las tres oficinas dependen administrativamente de la zona registral con sede en Tacna, pero el equipamiento se instala en Moquegua, Ilo y Juliaca.

5.5 Jurisdicciones mencionadas

Cada asignación registra las jurisdicciones de Tacna que su denominación nombra, cotejando el texto contra los veintiocho distritos y las cuatro provincias, con las variantes que introduce el reconocimiento óptico. Para los pliegos locales la jurisdicción es la propia. La variable permite responder qué recibe cada distrito sin depender de que la obra esté en su pliego: 509 de las 854 asignaciones nombran al menos una jurisdicción.

6. Catálogo por pliego y script de control

6.1 Catálogo

El catálogo se deriva agrupando las dos bases por código de pliego, con el departamento como variable. Ninguna entidad se agrega a mano, de modo que no puede desincronizarse de lo que describe. Resultan 78 pliegos: dos regionales, veintisiete nacionales y cuarenta y nueve locales.

- El monto suma solo las filas de la base no duplicada. Las del Anexo 8 van en columnas propias.
- La columna que declara qué mide el monto es indispensable, porque la regla cambia: para los pliegos con sede en el departamento es el presupuesto institucional completo; para los ministerios es solo la porción localizada allí. Las dos cifras no son comparables y no deben sumarse sin advertirlo.
- La desagregación por fuente y el peso de los recursos determinados se calculan sumando las líneas del Anexo 7, no tomando un agregado, así que son verificables línea por línea.
- Los tres sectores de mayor monto de cada pliego se resumen en una columna, y la referencia de páginas comprime las consecutivas en rangos.

6.2 Script de control

Los anexos no son partes de una tabla sino cortes distintos del mismo dinero, así que la ausencia de duplicación no puede darse por supuesta: hay que verificarla. El script hace cuatro comprobaciones y devuelve código de salida distinto de cero si alguna falla, para encadenarlo en un proceso automático.

```
python3 control-asignaciones.py base.csv [--ref ref4.json]
```

- Partición por nivel de gobierno. Los anexos 5, 6 y 7 cubren conjuntos de pliegos disjuntos porque cada uno corresponde a un nivel distinto. Una intersección delata un error de lectura.
- Contención de los cortes transversales. El Anexo 8 reorganiza por programa presupuestal dinero ya consignado en los anexos 6 y 7, de modo que en ningún pliego puede exceder su base. Esta comprobación detectó por sí sola que un pliego de Moquegua estaba incompleto, antes de que lo hiciera el cierre.
- Ausencia de filas idénticas repetidas dentro de un mismo anexo.
- Cierre por pliego contra el total impreso, salvo en los pliegos nacionales, que aportan solo su porción territorial y quedan marcados como no aplicables.

Sobre las dos bases el control corre sin observaciones.

7. Controles de validación

Cada bloque se valida contra un subtotal impreso en el propio anexo. Estos son los controles aplicados y sus resultados:

Control	Resultado (S/)	Estado
Hojas del pliego 460 contra su total impreso, Tacna	986 582 046	Cuadra
Hojas del pliego 455 contra su total impreso, Moquegua	768 940 447	Cuadra
Universidad Jorge Basadre Grohmann, pliego 531	176 845 803	Cuadra
Universidad Nacional de Moquegua, pliego 545	64 616 600	Cuadra
Anexo 7, los 28 pliegos locales de Tacna	1 186 851 544	28 de 28
Anexo 7, los 21 pliegos locales de Moquegua	1 015 567 508	21 de 21
Anexo 8 contra la base que replica, ambas regiones	692 002 101 y 498 984 962	Sin excesos

Control	Resultado (S/)	Estado
Catálogo por pliego contra las dos bases	4 590 490 603	Cuadra

Los controles no son un trámite final: son el instrumento que permite corregir sin conjeturas. La reparación opera en tres niveles y siempre por diferencia contra una cifra impresa, nunca por estimación. Si a un producto le falta el importe de una sola actividad, se recupera restando las hermanas de su total. Si falta el de un solo proyecto, se recupera contra el subtotal de su subsección. Y si a un pliego le falta o le sobra un importe y existe una única línea cuyos componentes no reconcilian con su propio total, la diferencia se imputa ahí. Cuando hay más de una candidata la rutina no actúa: reparte a ciegas sería peor que dejar la marca.

El criterio de qué referencia manda también está resuelto. El total del Anexo 4 se acepta solo si sus propias fuentes lo suman; cuando el reconocimiento óptico dañó un dígito del total, la suma de fuentes prevalece. Así se resolvió el caso de la Municipalidad Provincial de Tarata, impresa como 7 918 284 en un anexo y 7 918 264 en otro.

8. Incidencias de reconocimiento óptico

Toda corrección se resuelve por diferencia contra una cifra impresa, nunca por estimación, y queda registrada con su lectura original para que pueda verificarse contra el PDF.

Pliego	Genérica	Incidencia	Lectura del OCR	Valor adoptado
230108 Pocollay	2.5 Otros gastos	Total impreso ilegible	29 460	129 460
230203 Camilaca	2.1 Personal	Total impreso ilegible	268 300	268 360
230203 Camilaca	2.1 Personal	Componente corregido por cierre de pliego y de fuente	244 660	244 600
230301 Locumba	2.6 Activos no financieros	Total impreso ilegible	84 189 984	84 169 984
230303 Ite	2.3 Bienes y servicios	Celda partida por el OCR	101 535	10 067 168

El caso de Ite es ilustrativo. La celda de recursos determinados se imprimió como «101367 168», que el lector interpreta como dos números. El valor correcto, 10 067 168, se obtiene restando al total de la línea el componente de recursos directamente recaudados, y coincide con la diferencia entre el agregado de gasto corriente y las demás subgenéricas.

Se corrigieron además tres denominaciones deformadas: Calana, Palca y La Yarada Los Palos aparecían como «Galana», «Paica» y «La Varada». La corrección se aplicó en la base y no solo en la presentación, porque el nombre del pliego es la clave de unión con el catálogo.

9. Diccionario de variables

9.1 Base de asignaciones

854 filas para Tacna y 709 para Moquegua, con el mismo esquema, en UTF-8 con marca de orden de bytes y separador de punto y coma. La base de Moquegua añade departamento, nota, cuadre y diferencia del pliego.

Variable	Contenido	Valores o formato
anexo	Anexo del proyecto de ley	5, 6, 7, 8, A
archivo_pdf	Archivo de origen	Nombre del PDF
pagina_pdf / paginaimpresa	Página en el PDF y numeración correlativa del proyecto	Entero
nivel_gobierno	Nivel de gobierno del pliego	Nacional, regional o local
codigo_pliego / pliego	Entidad titular del presupuesto	Tres dígitos, o seis en locales
provincia / distrito	Jurisdicción del pliego local	Vacío en nacionales y regional
jurisdicciones_mencionadas	Distritos y provincias que nombra la denominación	Separados por barra vertical
categoria_presupuestal	Categoría a la que pertenece la partida	Programas presupuestales, acciones centrales, APNOP
programa_presupuestal	Programa, en las filas del anexo 8	Denominación; el anexo no asigna código
producto	Producto padre, en las actividades	Código y denominación
codigo_partida	Código de la partida	Siete dígitos iniciados en 2, 3 o 5; genérica del gasto; vacío
tipo_partida	Naturaleza de la asignación	Actividad, proyecto de inversión, producto sin actividades, genérica del gasto, asignación por programa presupuestal, subvención
concepto	Denominación de la partida	Texto
fuelle_financiamiento	Fuente, donde el anexo la desagrega	Cinco valores; solo en el anexo 7
monto_soles	Monto asignado	Entero sin separadores
alcance_territorial	Dónde se ejecuta la obra o el servicio	Localizada en Tacna; multidepartamental, incluye Tacna
base_no_duplicada	Si la fila puede sumarse con las demás	Sí; No, replica los anexos 6 y 7

9.2 Catálogo por pliego

78 filas y 30 columnas, las dos regiones en una sola tabla. La clave es el par de departamento y código de pliego.

Variable	Contenido	Valores o formato
departamento	Región a la que corresponde la fila	Tacna o Moquegua
codigo_pliego / pliego	Clave de unión y denominación	Texto
sectores_principales	Los tres sectores de mayor monto del pliego	Texto con montos
nivel_gobierno / provincia / distrito	Ubicación institucional	Texto

Variable	Contenido	Valores o formato
anexos	Anexos donde aparece el pliego	Lista separada por comas
n_asignaciones / monto_asignado_soles	Filas y monto de la base no duplicada	Entero
n_proyectos_inversion / monto_...	Proyectos de inversión del pliego	Vacío si no tiene
n_actividades / monto_...	Actividades del pliego	Vacío si no tiene
n_genericas_gasto / monto_...	Genéricas del gasto del pliego	Solo gobiernos locales
monto_programas_presupuestales	Monto en esa categoría	Vacío si no aplica
monto_acciones_centrales / monto_apnop	Monto en esas categorías	Vacío si no aplica
recursos_ordinarios y las tres siguientes	Desagregación por fuente	Solo gobiernos locales
pct_recursos_determinados	Peso de los recursos determinados	Decimal con coma
n_asignaciones_anexo8 / monto_anexo8	El cruce por programa presupuestal, en columnas aparte	Entero
partidas_multidepartamentales	Partidas de alcance más amplio que el departamento	Entero o vacío
referencia_paginas_pdf	Páginas por archivo, con rangos comprimidos	Texto

10. Advertencias de uso

- Las 170 filas del Anexo 8 replican por programa presupuestal recursos ya consignados en los anexos 6 y 7. Filtrar por la variable de base no duplicada antes de sumar.
- Las tres partidas multidepartamentales abarcan varios departamentos y solo una fracción indeterminada corresponde a Tacna. La mayor son los 18 000 000 del Instituto Nacional de Innovación Agraria en 33 distritos de diez departamentos.
- Los recursos determinados no son sinónimo de canon. La fuente agrupa canon y sobrecanon, regalías, renta de aduanas y participaciones, contribuciones a fondos, impuestos municipales y Fondo de Compensación Municipal. El desglose por rubro no está en los anexos.
- Las asignaciones de diez mil soles o menos son en su mayoría partidas simbólicas de continuidad, que habilitan la línea sin financiar ejecución significativa.
- Se trata de un proyecto de ley. Las cifras cambian con el debate parlamentario y con la autógrafa; las bases reflejan el texto remitido el 27 de agosto de 2026.
- El sector es una clasificación funcional derivada de la denominación de la partida, de su producto padre y del programa presupuestal, con reglas ordenadas donde la primera coincidencia decide. Las líneas del Anexo 7 no admiten sector, porque el anexo abre por genérica del gasto y no por función: llevan el valor «No sectorizable», que es una constatación del anexo y no una falla de la clasificación.
- Cualquier cifra que vaya a citarse textualmente en un documento oficial debe verificarse contra el PDF original en la página indicada, por la naturaleza del reconocimiento óptico.

11. Secuencia de replicación

1. Copiar los PDF a disco local; verificar páginas y capa de texto.
2. Extraer el texto conservando la disposición espacial y separar por páginas.

3. Identificar los códigos de pliego del departamento de interés. Para otro departamento cambian los dos primeros dígitos del código municipal y el código del gobierno regional, que se verifica por el orden alfabético del anexo 6.
4. Recorrer los once archivos buscando esos códigos, nunca el nombre del departamento.
5. Reconstruir el árbol de cada anexo y conservar solo las hojas, comprobando si algún nodo intermedio carece de hijos.
6. Concatenar los nombres partidos en varias líneas antes de aplicar cualquier filtro de texto.
7. Leer el anexo 7 por posición de columna, con el último número de cada línea como total y las fuentes candidatas restringidas por el anexo 4.
8. Clasificar las partidas nacionales por su bloque de ubicación y descartar las que se ejecutan fuera del departamento.
9. Ejecutar los ocho controles de la sección 7. Si alguno no cuadra, localizar la línea y resolver por diferencia contra una cifra impresa, documentando la corrección.
10. Derivar el catálogo agrupando la base por código de pliego y comprobar que cierre contra ella.

El paso decisivo es el de los controles. Los controles no son un trámite final: cada descuadre detectado en este trabajo señaló un defecto real de lectura —el arrastre del encabezado, la alineación de columnas, cinco celdas dañadas— y ninguno se resolvió ajustando la cifra al resultado esperado.